Revista Científica Soldado do Fogo



Corpo de Bombeiros Militar do Estado do Rio de Janeiro

2 de dezembro de 2025

Sistemas inteligentes de monitoramento para incêndios florestais: uma revisão sistemática

Autores:

Lucas Leocadio Gonçalves
Graduado no Curso de Formação de Oficiais da ABMDPII
Instituição: CBMERJ
E-mail: lukasleocadio11@gmail.com

Guilherme Martins Botelho
Graduado no Curso de Formação de Oficiais da ABMDPII
Instituição: CBMERJ
E-mail: gbotelhom@gmail.com

Thiago de Barros Ramos
Mestre em Educação Física pela Universidade Federal do Rio de Janeiro
Instituição: CBMERJ
E-mail: barros.cbmerj@gmail.com

SECRETARIA DE ESTADO DE DEFESA CIVIL
CORPO DE BOMBEIROS MILITAR DO ESTADO DO RIO DE JANEIRO
REVISTA CIENTÍFICA SOLDADO DO FOGO

SISTEMAS INTELIGENTES DE MONITORAMENTO PARA INCÊNDIOS FLORESTAIS: UMA REVISÃO SISTEMÁTICA

Lucas Leocadio Gonçalves[1]* Guilherme Martins Botelho[2]* Thiago de Barros Ramos[3]

[1]Corpo de Bombeiros Militar do Estado do Rio de Janeiro (CBMERJ). E-mail: lukasleocadio11@gmail.com. ORCID: 0009-0003-1063-3661. *Autor correspondente.
[2]Corpo de Bombeiros Militar do Estado do Rio de Janeiro (CBMERJ). E-mail: gbotelhom@gmail.com. ORCID: 0009-0004-6727-576X
[3]Corpo de Bombeiros Militar do Estado do Rio de Janeiro (CBMERJ). E-mail: barros.cbmerj@gmail.com ORCID: 0000-0002-3850-4445

RESUMO: Este estudo examina a crescente preocupação com os incêndios florestais no Brasil, com ênfase no Estado do Rio de Janeiro, região fortemente impactada pelo desmatamento e pela urbanização desordenada. Analisa-se a limitada eficácia dos métodos convencionais de monitoramento, como a observação por satélite e a vigilância presencial em campo, e propõe-se a implementação de um sistema de monitoramento assistido por inteligência artificial (IA). Tal sistema integra sensores avançados e algoritmos de aprendizado de máquina com o objetivo de viabilizar a detecção precoce e uma resposta operacional mais eficiente aos incêndios florestais. Foi conduzida uma revisão sistemática da literatura, que resultou na inclusão de 22 estudos relevantes, adotando-se uma abordagem quali-quantitativa para análise das características e do desempenho de diferentes tecnologias baseadas em IA, tais como redes neurais convolucionais (CNNs), sensores remotos e veículos aéreos não tripulados (UAVs). Os achados indicam que a aplicação de IA pode incrementar de forma significativa a precisão e a eficácia na identificação de focos de incêndio, superando as limitações observadas nos métodos tradicionais de monitoramento. Concluiu-se que a implementação de um sistema de monitoramento de incêndios florestais baseado em IA no âmbito do CBMERJ apresenta potencial para aprimorar a capacidade de resposta a incêndios, contribuindo para a proteção do meio ambiente e da população. Contudo, ressalta-se a necessidade de estudos adicionais voltados à adaptação e à otimização dessas tecnologias ao contexto específico da região.
Palavras-chave: Algoritmos; Aprendizado de Máquina; Proteção Ambiental; Sensores Remotos; Tecnologias Emergentes.

ABSTRACT: This study examines the growing concern about wildfires in Brazil, with an emphasis on the state of Rio de Janeiro, a region heavily affected by deforestation and unplanned urbanization. It analyzes the limited effectiveness of conventional monitoring methods, such as satellite observation and in-person field surveillance, and proposes the implementation of an artificial intelligence (AI)-assisted monitoring system. This system integrates advanced sensors and machine learning algorithms with the aim of enabling early detection and a more efficient operational response to wildfires. A systematic literature review was conducted, resulting in the inclusion of 22 relevant studies, and a mixed-methods (qualitative–quantitative) approach was adopted to analyze the characteristics and performance of different AI-based technologies, such as convolutional neural networks (CNNs), remote sensors, and unmanned aerial vehicles (UAVs). The findings indicate that the application of AI can significantly enhance the accuracy and effectiveness of fire-spot detection, overcoming the limitations observed in traditional monitoring methods. The study concludes that implementing an AI-based wildfire monitoring system within CBMERJ has the potential to improve the institution's capacity to respond to fires, thereby contributing to the protection of the environment and the population. Nevertheless, further studies are required to adapt and optimize these technologies to the specific context of the region.
Keywords: Algorithms; Machine Learning; Environmental Protection; Remote Sensors; Emerging technologies.

1. INTRODUÇÃO

Os incêndios florestais são, no Brasil, uma preocupação crescente em razão do aumento das ações de desmatamento e de atividades humanas descontroladas[1]. Esses fatores são influenciadores diretos da propagação rápida do fogo em diferentes regiões do país, afetando ecossistemas e comunidades. O Rio de Janeiro é um exemplo paradigmático de cidade marcada pela urbanização exacerbada, sem planejamento e com graves consequências sociais e ambientais[2]. Esse cenário cria condições propícias para a ocorrência de incêndios florestais frequentes e de relevante magnitude[3].

De acordo com a Classificação e Codificação Brasileira de Desastres (COBRADE), Incêndio Florestal é toda propagação de fogo sem controle, em qualquer tipo de vegetação situada em áreas legalmente protegidas. Devido à complexidade e a magnitude desses eventos, a prevenção é considerada um ponto-chave na preservação desses ecossistemas. O conceito de prevenção a incêndios florestais pode ser compreendido como o conjunto de medidas, normas e atividades destinadas a evitar esses incêndios e a impedir a propagação do fogo,[3].

Nesse contexto, a detecção de incêndios florestais no Brasil ainda é um processo relativamente oneroso e, em alguns casos, ineficiente, assim como as atuais técnicas de monitoramento, que utilizam rede de satélites com diferentes sensores ópticos e observadores humanos para detectar focos de incêndio[4]. No Estado do Rio de Janeiro, o monitoramento é realizado de forma fixa, por meio de torres de observação, ou de forma móvel, por patrulhamento terrestre e aéreo, contando também com o apoio do Centro de Previsão do Tempo e Estudos Climáticos (CPTEC), que identifica possíveis focos de incêndio por imagens de satélite e aciona imediatamente o Corpo de Bombeiros do Estado do Rio de Janeiro[5]

Em contraste com essa metodologia, o monitoramento assistido por câmeras[6], ganhou grande relevância na gestão ambiental em razão da evolução das técnicas e equipamentos de processamento digital de imagens. Esta nova abordagem[7], permite fornecer dados suplementares sobre o incêndio, como suas proporções e localização por meio da visualização de imagens, além de possibilitar a integração de aplicações avançadas nessas câmeras, garantindo detecções ágeis, precisas e independentes de intervenção humana.

Os incêndios florestais geram impactos significativos em diferentes esferas do meio ambiente e da sociedade. No meio físico, ocorrem aquecimento do solo, erosão, redução de nutrientes e matéria orgânica, alterações no microclima local, liberação de carbono para a atmosfera e diminuição da qualidade da água. No meio biótico, destacam-se a mortandade de animais, danos à madeira, interferências na sucessão vegetal, redução da atividade de microrganismos e renovação da pastagem. Além disso, os incêndios acarretam prejuízos

socioeconômicos, como transtornos às populações próximas, destruição de áreas de lazer e turismo, além de impactos paisagísticos que afetam negativamente a beleza cênica e a funcionalidade dos ecossistemas[8].

O monitoramento atual via satélite se mostra ineficiente em alguns aspectos devido a algumas condições que impedem ou prejudicam muito a detecção das queimadas[9]. São elas:

- Nuvens cobrindo a região (exceto nuvens de fumaça);
- Fogo apenas no chão de uma floresta densa, sem afetar a copa das árvores;
- Frentes de fogo com menos de 30 m;
- Queimada de pequena duração, ocorrendo entre as imagens disponíveis;
- Imprecisão na localização do foco de queima, que no melhor caso é de cerca de 1 km, mas podendo chegar a 6 km;
- Fogo em uma encosta de montanha, enquanto que o satélite só observou o outro lado.

A implementação desse modelo tecnológico baseado em IA pode contribuir de maneira substancial para o gerenciamento de incidentes de incêndio florestal, pois permite identificar com precisão a localização do foco, observar o ponto inicial do evento e conhecer a extensão do incêndio, facilitando a rápida determinação dos recursos a serem empregados[10].

Experiências positivas foram encontradas em trabalhos relativos ao tema e em modelos semelhantes vigentes em outros países. No estado da Califórnia/EUA, por exemplo, um sistema denominado de ALERTCalifornia foi implementado pela Universidade de San Diego.

Neste caso, as câmeras do sistema conseguem realizar panorâmica, inclinação, zoom e varreduras de 360 graus aproximadamente a cada dois minutos com 12 quadros de alta definição (HD) por varredura. Elas também fornecem monitoramento 24 horas com recursos de visão noturna de infravermelho próximo. Cada câmera pode ver até 60 milhas em um dia claro, e 120 milhas em uma noite clara. Usando esse recurso e ferramentas associadas, os socorristas do Departamento de Florestas e Proteção contra Incêndios da Califórnia (CAL FIRE) podem confirmar rapidamente a ignição do fogo, dimensionar com agilidade os equipamentos de combate, apoiar evacuações por meio de uma consciência situacional aprimorada e monitorar os incêndios até a sua contenção[11].

Na busca por soluções eficazes para o monitoramento e combate a incêndios florestais, diversos estudos têm sido realizados em diferentes partes do mundo, com foco principalmente em biomas como florestas temperadas e boreal. O desenvolvimento de um sistema de Inteligência Artificial (IA) para monitoramento de incêndios em florestas temperadas da região oeste dos Estados Unidos. Eles utilizaram dados de satélite e técnicas avançadas de processamento de imagens para detectar incêndios em estágios iniciais e prever sua propagação com maior precisão[12].

O uso de algoritmos de IA para monitoramento de incêndios em florestas boreais do Canadá. Utilizando uma combinação de dados de sensoriamento remoto e modelos de aprendizado de máquina, os pesquisadores identificaram padrões de incêndios e previram áreas de alto risco com antecedência, possibilitando uma resposta mais eficiente das autoridades[13].

Esses estudos destacam a eficácia potencial da IA no monitoramento e prevenção de incêndios florestais em diferentes contextos. No entanto, é importante ressaltar que as características únicas regionais representam desafios adicionais que requerem adaptações específicas nos modelos e algoritmos de IA. A densidade da vegetação, a diversidade de espécies e as condições climáticas variáveis são fatores que exigem uma abordagem personalizada para o desenvolvimento de sistemas de IA adequados às necessidades do Corpo de Bombeiros Militar do Estado do Rio de Janeiro (CBMERJ) e da região da Mata Atlântica, por exemplo.

Assim, a integração de conhecimentos e técnicas de diferentes áreas, como sensoriamento remoto, ciência de dados e engenharia florestal, será essencial para o desenvolvimento de soluções eficazes e sustentáveis para o monitoramento e combate a incêndios florestais nesta importante região brasileira.

A adaptação dos sistemas de IA às realidades operacionais implica na integração da infraestrutura tecnológica existente com os protocolos de operação dos bombeiros. A interface do sistema deve ser projetada para facilitar o uso em situações de emergência, levando em consideração a capacidade de treinamento e suporte técnico disponível.

Adicionalmente, a validação científica do sistema requer testes, considerando diferentes cenários e condições climáticas da Mata Atlântica, avaliando o impacto na redução do tempo de resposta, na área queimada e nos danos causados pelos incêndios. Uma análise de custo-benefício também é necessária para indicar a viabilidade econômica da implementação em larga escala.

Considerações éticas e sociais também são relevantes.A implementação de sistemas de IA no combate a incêndios florestais levanta importantes questões éticas, incluindo a privacidade de dados, a responsabilidade em caso de falhas e o impacto no trabalho dos bombeiros. A tecnologia avançada pode ser utilizada para prevenir e gerenciar incêndios florestais, mas também alertam para a necessidade de estabelecer diretrizes claras que garantam o uso responsável e ético dessas ferramentas, ressaltando que, apesar dos avanços tecnológicos, é fundamental assegurar a segurança dos dados e definir responsabilidades em caso de falhas[14].

Sendo assim, um sistema de monitoramento de incêndios florestais com IA no Rio de Janeiro tem o potencial de aprimorar significativamente a resposta a incêndios, protegendo o meio ambiente e a população. No entanto, a lacuna científica identificada destaca a necessidade de pesquisas e adaptações específicas para o contexto da Mata Atlântica e do CBMERJ.

Desta forma, o presente estudo visa analisar a utilização de sistemas de monitoramento de incêndios florestais controlados por inteligência artificial em diversos biomas. Serão investigadas as características singulares de regiões com diferentes tipos de vegetação e condições climáticas, que influenciam o enfrentamento desses desastres naturais. Em seguida, serão analisados estudos anteriores sobre o uso de IA em biomas como florestas temperadas e boreais, com o intuito de identificar insights relevantes e adaptáveis a outras áreas geográficas. A pesquisa visa também observar e estudar modelos e algoritmos de IA específicos que se adequem a esses contextos, levando em conta a densidade vegetal, a diversidade de espécies, e outros fatores ambientais que impactam a eficácia desses sistemas.

2. MÉTODOS

Para alcançar os objetivos propostos, foi realizada uma revisão sistemática com abordagem qualiquantitativa, seguindo os Principais Itens para Relatar Revisões Sistemáticas e Meta-Análises: A Recomendação PRISMA (Preferred Reporting Items for Systematic Reviews and Meta-Analyses)[15]. Essa metodologia garantiu rigor metodológico e transparência na análise dos dados e na interpretação dos resultados.

A condução da revisão seguiu as recomendações do protocolo PRISMA, garantindo maior transparência e reprodutibilidade do processo. Inicialmente, foi definida a pergunta de pesquisa e delimitado o escopo temático, contemplando sistemas inteligentes baseados em inteligência artificial, visão computacional e sensoriamento remoto aplicados ao monitoramento de incêndios florestais. Em seguida, foram estabelecidos, de forma prévia, os critérios de inclusão e exclusão, a estratégia de busca, o método de extração das informações e o procedimento de avaliação da qualidade dos estudos. O fluxo de seleção contemplou as etapas de identificação, triagem, elegibilidade e inclusão dos artigos, sendo todas as fases sistematicamente registradas em um diagrama de fluxo PRISMA, no qual constam os números de estudos inicialmente encontrados, os excluídos por duplicidade ou inadequação ao tema e aqueles efetivamente incluídos na síntese final.

A busca foi realizada, de forma estruturada, nas bases de dados Google Scholar e IEEE Xplore, selecionadas por sua abrangência em literatura científica e técnica nas áreas de engenharia, computação, visão computacional e sistemas inteligentes aplicados a incêndios florestais. Essas bases permitem acesso a artigos de periódicos, anais de congressos, relatórios técnicos e outros documentos relevantes para o tema. A estratégia de busca combinou descritores em português e em inglês relacionados a “incêndios florestais”, “detecção precoce”, “visão computacional”, “deep learning”, “redes neurais convolucionais”, “sensoriamento remoto”, “imagens de satélite”, “câmeras de vigilância” e “sistemas inteligentes de monitoramento”,

associados por meio de operadores booleanos (AND e OR). A partir dos resultados brutos, foram aplicados filtros por pertinência temática e disponibilidade de texto completo, sendo excluídos trabalhos que não tratavam diretamente de monitoramento ou detecção de incêndios florestais por meio de soluções baseadas em inteligência artificial ou que apresentavam foco predominantemente teórico, sem aplicação prática ou experimental.

Os descritores utilizados na pesquisa foram definidos com base em termos relacionados ao monitoramento e prevenção de incêndios florestais, combinados com tecnologias avançadas e inteligência artificial. A estratégia de busca incluiu os seguintes descritores: ('wildfire monitoring' OR 'forest fire monitoring' OR 'wildfire detection' OR 'forest fire detection' OR 'wildfire prevention' OR 'forest fire prevention') AND ('advanced technologies' OR 'cutting-edge technologies' OR 'remote sensing' OR 'satellite imagery' OR 'drones' OR 'UAVs' OR 'sensor networks') AND ('artificial intelligence' OR 'AI' OR 'machine learning' OR 'ML' OR 'deep learning'). Os critérios de inclusão englobam estudos que abordaram a aplicação de inteligência artificial no monitoramento de incêndios florestais, avaliando sua eficácia, precisão e confiabilidade, além de analisar os custos de implementação e manutenção desses sistemas.

Por outro lado, foram excluídos estudos de revisão sistemática, de literatura e estudos de caso, assim como aqueles que não apresentavam metodologia detalhada ou resultados completos. Também não foram considerados os estudos que: não mencionaram o uso de IA ou que se concentram em outras tecnologias de monitoramento; não forneceram dados sobre a capacidade das IA em auxiliar na detecção de incêndios; não abordaram questões relacionadas à precisão dos dados ou questionam a confiabilidade das informações obtidas; não discutiram a aplicação prática desses dispositivos em sistemas de prevenção e combate a incêndios; não consideraram aspectos econômicos ou não avaliaram a viabilidade financeira da utilização de câmeras para este fim; e não consideraram as possíveis consequências ambientais ou sociais da implementação de sistemas de câmeras.

Ao todo, 22 estudos foram selecionados para análise. Esses estudos foram comparados quanto à eficácia e precisão dos sistemas de monitoramento suportados por IA em diferentes tipos de vegetação e contextos ambientais. Para tanto, foram extraídas as seguintes variáveis independentes: autor, tipo de tecnologia de IA, características técnicas, área geográfica de estudo, configuração dos algoritmos, ambiente de implementação; E as seguintes variáveis dependentes foram consideradas: ano da publicação, precisão na detecção de incêndios, tempo de resposta, e custo-efetividade. Essas variáveis possibilitam avaliar o desempenho e a viabilidade dos sistemas de IA para monitoramento de incêndios florestais em diferentes cenários.

Os dados obtidos foram analisados de forma qualitativa e quantitativa. A abordagem qualitativa incluiu a análise temática e de conteúdo, permitindo a identificação de padrões e

tendências nos estudos revisados, enquanto a abordagem quantitativa se focou na interpretação dos dados numéricos e estatísticos apresentados pelos estudos. A análise procurou não apenas identificar resultados isolados, mas também compreender as implicações práticas e os desafios das soluções de monitoramento por IA.

Quanto ao risco de viés, foi utilizada a ferramenta Cochrane Risk of Bias Tool (RoB), amplamente reconhecida por sua aplicação na avaliação sistemática de viés em estudos clínicos e de intervenção, adaptada para o contexto de monitoramento de incêndios florestais. A ferramenta foi utilizada, por exemplo, que aplicou a versão revisada da ferramenta, RoB 2, para examinar viés de seleção, desempenho e relato, fornecendo uma estrutura detalhada para avaliar o risco em ensaios controlados randomizados[16]. Foram examinados cinco tipos de viés: viés de seleção, relacionado à possível tendência de favorecer certos sistemas de detecção; viés de desempenho, que avalia as diferenças na implementação dos sistemas entre os estudos; viés de detecção, verificando potenciais vieses devido a métodos inconsistentes de medição dos resultados; viés de desistência, relacionado à perda significativa de dados ao longo dos estudos; e viés de relato, considerando a possibilidade de os resultados serem selecionados com base em sua relevância para a pesquisa.

As classificações de risco de viés foram atribuídas como Incerto (I), Baixo (B) ou Alto (A) e os resultados foram apresentados em forma de tabela, permitindo uma análise clara da qualidade metodológica de cada estudo.

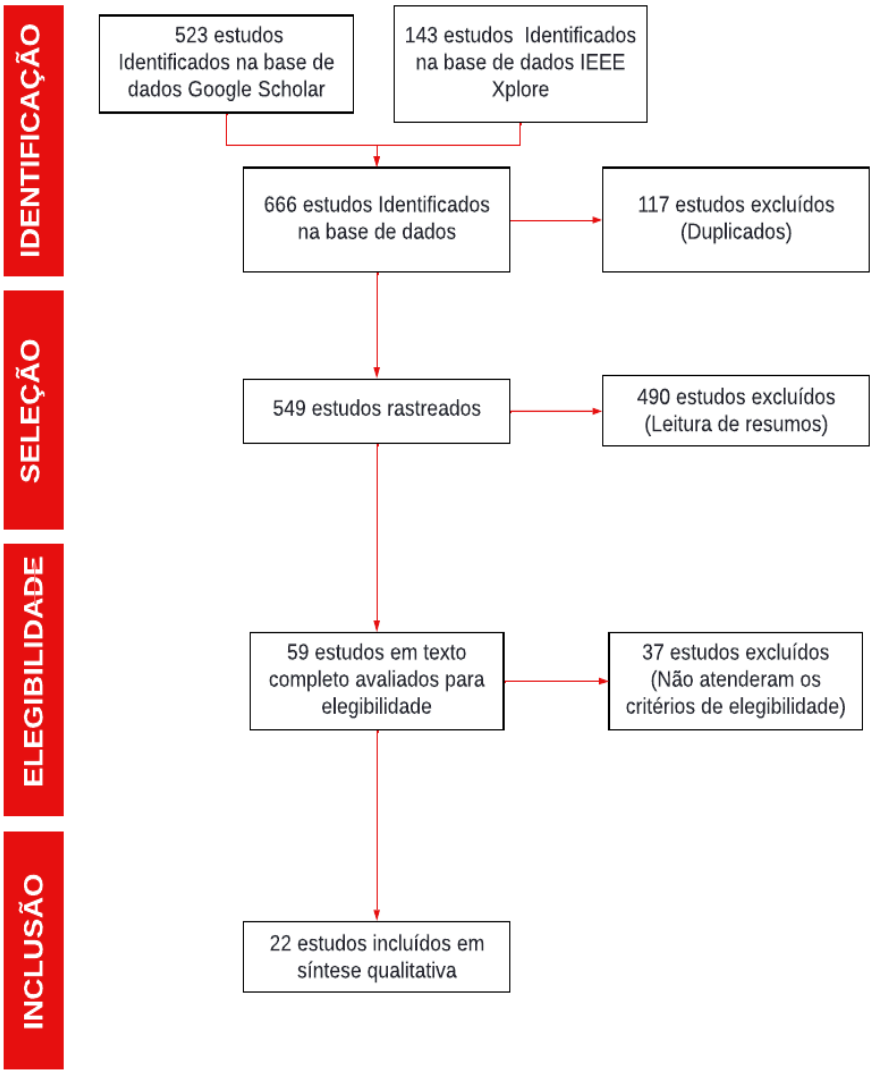
A avaliação dos estudos foi realizada de forma independente por dois pesquisadores, que analisaram os dados de maneira cega, sem conhecimento das decisões do outro, para evitar influências. Como houve concordância significativa entre os avaliadores, não foi necessária a intervenção de um terceiro revisor.

Por fim, todos os procedimentos seguiram os princípios éticos da pesquisa científica, assegurando a transparência e integridade em todas as etapas da revisão.

3. RESULTADOS

Um total de 666 estudos foram identificados na primeira busca, sendo que, após a remoção de duplicatas e a aplicação dos critérios de elegibilidade, restaram 22 pesquisas para a síntese qualitativa. O processo de seleção seguiu o fluxograma recomendado pela metodologia de Principais Itens de Relatório Preferenciais para Revisões Sistemáticas e Meta-Análises (PRISMA), conforme ilustrado na Figura 1, detalhando as etapas de identificação, triagem, elegibilidade e inclusão dos estudos na revisão sistemática.

Figura 1 – Diagrama de fluxo PRISMA dos estudos levantados na revisão sistemática



Fonte: Desenvolvida pelos autores.

Em linhas gerais, houve predominância de classificações de baixo risco nos diversos domínios avaliados quanto ao viés. Dos 22 estudos analisados, 41% (9 estudos) foram classificados como baixo risco para o viés de seleção, enquanto 59% (13 estudos) foram considerados de baixo risco para o viés de desempenho. No entanto, quanto ao viés de detecção, 63% (14 estudos) dos estudos apresentaram um grau de incerteza elevado. Quanto ao viés de desistência, a maioria esmagadora (86%, correspondendo a 19 estudos) foi avaliada como apresentando baixo risco. Por fim, para o viés de relato, 95% (21 estudos) dos estudos foram classificados como baixo risco. Esses resultados destacam uma tendência positiva em relação à robustez metodológica da maioria dos estudos analisados, embora a incerteza no viés de detecção seja observada em uma parcela significativa. Os resultados estão descritos na Tabela 1.

Tabela 1 – Avaliação do risco de viés

Nr	Autor	Riscos de viés avaliados				
		VS	VDs	VDt	VDss	VR
1	Saponara S. et al. (2021)	I	I	I	I	B
2	Xu Y. et al. (2024)	I	A	B	I	B
3	Govil K. et al. (2020)	I	A	I	B	I
4	Shamta I, Demir BE. (2024)	I	A	I	B	B
5	Kanwal R. et al. (2023)	B	B	I	B	B
6	Rad R. (2023)	I	B	B	B	B
7	Mohammed RK. (2022)	A	I	I	B	B
8	Sathishkumar V.E. et al. (2023)	A	B	I	B	B
9	Wang L. et al. (2023)	I	B	B	B	B
10	Young-Im C. et al.(2022)	I	B	B	B	B
11	Davis M, Shekaramiz M. (2023)	I	B	B	B	B
12	Duangsuwan S, Klubsuwan K. (2023)	A	B	I	B	B
13	Wei C. et al. (2023)	A	B	I	B	B
14	Oh SH. et al. (2020)	B	B	I	B	B
15	Cong PT, Tam NT. (2018)	I	I	I	B	B
16	George L. et al. (2023)	I	B	I	B	B
17	Rubab SF. et al (2023)	B	B	B	B	B
18	Shroff P. (2023)	I	B	I	B	B
19	Bushnaq OM. (2020)	I	A	I	B	B
20	Ghali R, Akhloufi MA. (2022)	B	B	B	B	B
21	Remmelzwaal L. (2023)	B	B	B	B	B
22	Pietro B. et al. (2023)	I	I	I	B	B

Fonte: Desenvolvida pelo autor.
Legenda: VS — Viés de Seleção; VDs — Viés de Desempenho; VDt — Viés de Detecção; VDss — Viés de Desistência; VR — Viés de Relato; B — baixo risco; A — alto risco; I — incerto.

Tabela 2 – Tecnologias de IA utilizadas nos estudos

Categoria de tecnologia de IA	Descrição resumida	Número de estudos	% sobre o total*
Deep Learning (CNN e arquiteturas afins)	Algoritmos de *deep learning* com ênfase em redes neurais convolucionais (CNNs)	20	0,91
Modelos específicos de DL (Xception, MobileNetV2, EfficientNet)	Subconjunto dos estudos com arquiteturas específicas para melhorar a precisão em imagens de satélite/câmeras	5	0,23
Machine Learning (Vision Transformer)	Estudo que utiliza técnicas de *machine learning* baseadas em Vision Transformers	1	0,05
Outras abordagens / não claramente especificadas	Abordagens que não ficam claramente classificadas apenas como DL ou ML no texto	1	0,05

Fonte: Desenvolvida pelo autor.
Legenda: Deep Learning = subárea do aprendizado de máquina que utiliza redes neurais profundas, com múltiplas camadas, capaz de extrair automaticamente padrões complexos dos dados; CNN (Convolutional Neural Network) = tipo de rede neural profunda especialmente projetada para processamento de imagens, muito usada para detecção e classificação de padrões visuais; Xception = arquitetura de rede neural convolucional que utiliza convoluções separáveis em profundidade, aumentando eficiência e desempenho em tarefas de visão computacional; MobileNetV2 = arquitetura de rede neural leve, otimizada para dispositivos com recursos computacionais limitados, como celulares e sistemas embarcados, mantendo boa performance em visão computacional; EfficientNet = família de redes neurais convolucionais que equilibra profundidade, largura e resolução de forma sistemática, alcançando alta acurácia com menor custo computacional; Machine Learning (ML) = área da inteligência artificial que desenvolve algoritmos capazes de "aprender" padrões a partir de dados, sem serem explicitamente programados para cada tarefa; Vision Transformer (ViT) = arquitetura de aprendizado de máquina que adapta o modelo Transformer, originalmente desenvolvido para processamento de linguagem, para tarefas de visão computacional, dividindo imagens em "patches" e tratando-os como sequências; DL = sigla para Deep Learning; ML = sigla para Machine Learning.

Os 22 estudos revisados nesta análise sistemática cobrem uma diversidade de abordagens para a detecção de incêndios florestais, utilizando tecnologias avançadas de Inteligência Artificial. A maioria das pesquisas avaliadas apresenta uma natureza experimental, com foco na aplicação prática de algoritmos de IA em sistemas de detecção, tanto em ambientes controlados quanto em cenários reais. Essas abordagens destacam o uso de redes neurais convolucionais, aprendizado profundo e sistemas baseados em sensores para aumentar a precisão e velocidade na identificação de focos de incêndio.

Por exemplo, o estudo de Mohammed[17] demonstrou a eficácia de um sistema de detecção em tempo real utilizando redes neurais convolucionais e Transfer Learning. Outros estudos são observacionais, investigando a eficácia das tecnologias de detecção em cenários específicos, como o trabalho de Gagliardi et al.[18], que analisou a aplicação de redes neurais convolucionais, You Only Look Once version 2 (YOLOv2), em ambientes diversos para a detecção de fumaça e fogo em tempo real. Além disso, há estudos que apresentam uma abordagem mais teórica, analisando a literatura existente ou propondo novas metodologias para a detecção de incêndios, como o estudo de Govil et al.[7], que explora o uso de Aprendizado Profundo (Deep Learning) em câmeras terrestres para a detecção precoce de incêndios florestais.

As tecnologias de IA predominantes apresentadas em 20 estudos, incluem algoritmos de deep learning, com ênfase significativa em CNNs. O estudo de Davis e Shekaramiz[19] ilustra o uso de técnicas de aprendizado profundo para detectar incêndios em desertos e florestas, atingindo uma precisão elevada. Além disso, cinco pesquisas exploraram modelos específicos, como Extreme Inception (Xception), MobileNetV2 e EfficientNet-B0, para aprimorar a precisão na detecção de incêndios a partir de imagens de satélite ou câmeras, como relatam Rubab et al.[20] . Por exemplo, Sathishkumar et al.[12] empregaram a arquitetura Xception em um sistema de detecção de incêndios e fumaça, atingindo 98.72% de precisão. Além disso, uma investigação utilizou técnicas de machine learning, como Vision Transformers, conforme explorado no estudo de Rad[21], para melhorar a eficiência e a precisão dos sistemas de detecção em ambientes complexos.

Os sistemas de detecção analisados possuem características técnicas variadas que dependem da tecnologia utilizada. Wei et al.[22] empregaram métodos de processamento de imagem para detecção em tempo real de incêndios florestais utilizando câmeras e aprendizado profundo. Bushnaq et al.[23] utilizaram sensores específicos, como câmaras multiespectrais e drones equipados com câmeras de alta resolução, para capturar dados relevantes e alimentar os algoritmos de IA. O estudo de Duangtawan e Klub Swan[24] destacou a utilização de drones com câmeras para monitorar queimadas em tempo real, empregando o modelo YOLOv5 combinado com LSTM. Além disso, sensores de baixo custo e sistemas embarcados foram implementados para monitoramento contínuo e em tempo real, como demonstrado no estudo de James et al.[25], que propôs um sistema de detecção leve e rápido, adequado para aplicações embarcadas.

Geograficamente, os estudos foram conduzidos em uma variedade de regiões, refletindo a diversidade dos biomas e das condições climáticas associadas aos incêndios florestais. James et al.[25] incluíram locais específicos como parques nacionais nos Estados Unidos, Oh et al.[26] florestas na Coreia do Sul e China, Davis e Shekaramiz[19] regiões desérticas nos Estados Unidos, e por fim Ghali e Akhloufi[14] áreas afetadas por incêndios na Austrália e Brasil. Essa distribuição geográfica amplia a relevância dos resultados, permitindo uma compreensão mais abrangente da eficácia dos sistemas de detecção em diferentes contextos ambientais.

As variáveis de avaliação mais comuns nos estudos incluíram a taxa de detecção de incêndios, a precisão dos modelos de IA, o tempo de resposta do sistema e a eficácia em diferentes condições climáticas e de iluminação. A precisão de detecção variou significativamente, onze trabalhos apresentaram acurácia de 95% ou superiores, como o de Tam e Cong[27], enquanto outros cinco estudos apresentaram métricas de desempenho ligeiramente inferiores, mas ainda robustas, entre 80 e 95%, como no estudo de Davis e Shekaramiz[19]. O tempo de detecção foi outro parâmetro crítico, com 5 sistemas operando em tempo real, como

demonstrado por Mohammed[18], detectando incêndios em frações de segundo, enquanto outros, como o estudo de Rad[21], apresentaram tempos de resposta mais lentos, refletindo a complexidade do cenário ou as limitações tecnológicas.

A metodologia de avaliação utilizada nesses estudos geralmente envolveu validação cruzada para testar a robustez dos modelos e análise estatística para quantificar a eficácia dos sistemas de detecção. O estudo de Sathishkumar et al.[12] utilizou validação cruzada para garantir a precisão de seu modelo de CNN, enquanto outros, como o estudo de Wei et al.[22], aplicaram testes de campo em ambientes naturais com câmeras baseadas em deep learning para validar os resultados obtidos em condições controladas. A combinação dessas abordagens metodológicas contribuiu para a obtenção de resultados confiáveis, garantindo que as tecnologias propostas possam ser aplicadas efetivamente em cenários reais de monitoramento de incêndios florestais. Os resultados das variáveis independentes e dependentes podem ser observados nas Tabelas 3 e 4.

Tabela 3 – Resultados das variáveis independentes

Nr	Autor	Tipo de Tecnologia de IA	Características Técnicas	Área Geográfica	Configuração dos Algoritmos	Ambiente de Implementação
1	Saponara S. et al.(2021)	YOLOv2 Convolutional Neural Network (CNN)	Arquitetura de rede neural leve, detecção em tempo real, processamento em plataforma embarcada	Não especificada	Treinamento offline, teste em vídeos de incêndio/fumaça em diferentes ambientes	MATLAB, NVIDIA Jetson Nano
2	Xu Y. et al.(2024)	Deep Learning (U-Net)	- Utilização de dados multiespectrais do Sentinel-2 (12 bandas) - Utilização de dados de aerossol do Sentinel-5P - Cálculo de índices espectrais (NBR e NDVI)	Novas Gales do Sul, Austrália	- Otimizador Adam - Taxa de aprendizado de 1e-4 - Tamanho do lote de 8 - 5000 iterações	Cluster com uma GPU NVIDIA A100
3	Govil K. et al.(2020)	Deep Learning (Inception V3)	- Detecção de fumaça em tempo real - Redução de falsos positivos com ajuste dinâmico de limiar	Califórnia, EUA	- Treinamento de modelo Inception V3 com dataset de imagens de fumaça - Segmentação de imagens em blocos de 299x299 pixels	Implementado em nuvem, integrando câmeras terrestres e dados de satélites
4	Shamta I, Demir BE.(2024)	Redes Neurais Convolucionais (CNN), Redes Neurais Recorrentes (RNN)	Utiliza UAV com câmera e Jetson Nano para processamento em tempo real. YOLOv8 e YOLOv5 para detecção de objetos e CNN-RCNN para classificação de imagens.	Florestas da Turquia	YOLOv8 e YOLOv5 para detecção rápida; CNN-RCNN combina CNN para extração de características e RNN para análise temporal.	UAV com NVIDIA Jetson Nano, interface de estação terrestre para visualização e gerenciamento de dados de detecção de incêndios.
5	Kanwal R. et al.(2023)	Convolutional Neural Network (CNN), Random Forest (RF), K-Nearest Neighbors (KNN), Support Vector Machine (SVM)	Uso de CNN 1D e 2D para extração de características, e diferentes técnicas de ML para predição de incêndios florestais	Paquistão	Modelos treinados usando CNN para melhorar a precisão; 512 variáveis foram usadas para melhorar a performance do RF	Implementado usando dados de satélite de sensoriamento remoto e sistemas de monitoramento de clima

6	Rad R.(2023)	Vision Transformer e CNN	U-shape Vision Transformer, Compact-Contextualize -Calibrate (C^3) block, Cascaded Atrous Pyramid Pooling (CAPP)	América do Norte	U-Shape Vision Transformer com blocos SP-Swin, uso de bandas SWIR1, SWIR2, HCHO, mapas de cobertura do solo e EI	Implementado em PyTorch, treinado com NVIDIA T4
7	Mohammed RK.(2020)	Deep Learning (Transfer Learning)	Utiliza a rede Inception-ResNet-v2 pré-treinada para extração de características; Avaliação da performance com ROC e AUC	Não especificada	Transfer learning com Inception-ResNet-v2, ajuste de hiperparâmetros, utilização de Adam optimizer e Softmax para classificação	Implementado em dispositivos Raspberry Pi com câmera e biblioteca OpenCV para detecção em tempo real
8	Sathishkumar VE. et al(2023)	Deep Learning	Utilização de redes neurais convolucionais pré-treinadas com Transfer Learning; Otimização de hiperparâmetros com Bayesian Optimization; LwF para evitar esquecimento catastrófico	Não especificada	Otimização de hiperparâmetros usando Bayesian Optimization; Ajuste fino de camadas superiores; Aplicação de LwF para preservar capacidades anteriores ao treinar novas tarefas	Laboratórios e testes com datasets de imagens
9	Wang L. et al(2023)	Deep Learning (CNN, SVM)	- Redução de parâmetros de VGGNet para classificação de imagens de incêndio florestal. - Extração de características espaciais e temporais com CNN otimizada. - Algoritmo Vibe para detecção de objetos em movimento.	Hangzhou, China	Não especificada	Dataset de incêndios florestais (FLAME) testado em laboratório universitário

10	Young IC. et al.(2023)	YOLOv8	sistema de detecção com o uso de UAVs para captura de imagens aéreas e o processamento dessas imagens utilizando o modelo YOLOv8.	Não especificada	Não especificada	Não especificada
11	Davis M, ShekaramizM.(2023)	Deep Learning	ResNet-50, Xception modificados, SVM, MobileNet	Utah, EUA	afinação de hiperparâmetros, busca aleatória de algoritmos de otimização, aumento de dados	Ambiente Python com TensorFlow e Keras
12	Klubsuwan K, Duangsuwan S.(2023)	Deep Learning	O estudo propõe um modelo que combina o detector YOLOv5 com um classificador LSTM leve para detecção de queimadas em tempo real a partir de imagens de drones.	Não Especficado	O framework Dr-TOBID foi desenvolvido usando OpenCV, YOLOv5, TensorFlow, LabelImg, Pycharm e OBS. Os dados foram divididos em 80% para treinamento e 20% para teste, com 200 épocas de treinamento.	O modelo de deep learning foi implementado em Python 3.7 na plataforma Anaconda. A estação de controle em solo utilizou um notbook para rodar o sistema
13	Wei C. et al(2022)	Deep Learning (aprendizado profundo)	YOLOv5S com MobilenetV3, Rede de Extração de Características em Múltiplas Escalas, Fusão Bidirecional de Características, 4 Detectores em Diferentes Escalas, Mecanismo de Atenção Coordenada	Não especificado	900 épocas, Otimizador SGD, Aumento de Dados	PyTorch 1.10, GPU Tesla V100-SXM2

14	Oh SH.(2020)	Deep Learning (aprendizado profundo)	CNNs para inferência em tempo real em dispositivos de baixo consumo.	Não especificada	Utiliza a função de perda Focal Loss para lidar com o desequilíbrio entre as classes (fogo e não fogo) e otimizador Adam com decaimento da taxa de aprendizado.	PyTorch. O treinamento e a avaliação foram realizados em uma estação de trabalho
15	Cong PT, Tam NT.(2019)	Deep Learning	Integra informações espectrais e espaciais com CNNs 3D; classificação pixel a pixel de incêndios.	América do Norte (EUA)	Otimização com Adam; treinamento com aumento de dados, normalização em lote, imagens em diferentes tempos.	Python com Keras, executado em GPU, CPU AMD Ryzen, 62 GB RAM; processamento em tempo real em nuvem.
16	James GL. et al.(2023)	CNN	Utiliza MobileNetV2 otimizada para dispositivos com recursos limitados. Treinado com dados aumentados para lidar com variações sazonais e de iluminação.	San Isabel National Park, Colorado, EUA	Otimização com ajuste de hiperparâmetros como taxa de dropout, número de neurônios na camada densa, profundidade da rede; aprendizado por transferência para acelerar a convergência.	Dispositivos com recursos limitados; suporte de plataforma em nuvem da Edge Impulse Inc.
17	Rubab SF. et al.(2024)	Deep Learning com XAI (MobileNetV3)	Combina Transfer Learning com LwF; utiliza MobileNetV3 adaptada e integra ferramentas XAI.	Não especificada	Otimizações nos hiperparâmetros, Transfer Learning, LwF para manter aprendizado sem esquecer conhecimento prévio.	Desenvolvido em TensorFlow e Keras; treinamento em GPUs do Google Colab, focado em eficiência computacional.
18	Shroff P.(2023)	Random Forest(Classificador de Floresta Aleatória)	O sistema WPDSS utiliza dados em tempo real da NASA e NOAA para prever e detectar incêndios.	Global	utiliza um classificador de floresta aleatória, ajustado com 7 "n-estimators" e "max-depth" de 5.	Drones são implantados para suprimir incêndios florestais em hotspots identificados.

19	Bushnaq OM. et al.(2023)	Redes UAV-IoT auxiliadas por Processos de Markov	Uso de UAVs e dispositivos IoT para detectar incêndios florestais com comunicação por redes de sensores e verificação de detecção por UAVs.	Canadá	Os sensores IoT detectam o incêndio com base em mudanças ambientais e comunicam-se com UAVs próximos.	Implementado em uma rede de UAVs e dispositivos IoT em florestas.
20	Ghali R, Akhloufi MA. (2022)	Deep Learning e Transformers.	Classificação de incêndios florestais usando um método de aprendizado profundo que combina os modelos EfficientNet-B5 e DenseNet-201. dois transformadores de visão e um modelo convolucional profundo.	Não especificada	Classificação: Modelos EfficientNet-B5 e DenseNet-201 combinados, perda de entropia cruzada categórica, otimizador Adam, aumento de dados com rotação, cisalhamento, zoom e deslocamento.	Máquina com TensorFlow, GPU NVIDIA Geforce RTX 2080Ti.
21	Remmelzwaal L.(2023)	Detecção de objetos usando YOLOv5	Sistema de detecção de incêndios usando câmeras HD panorâmicas, energia solar e um modelo de detecção de objetos baseado em YOLOv5,	Estados Unidos e Austrália	O modelo YOLOv5 analisa imagens em alta resolução para detectar padrões de fumaça e fogo. Foi treinado com 20.000 imagens	Implementado com câmeras panorâmicas HD e comunicação 4G para monitoramento em tempo real, alimentado por sistema de energia solar.
22	Pietro B. et al.(2023)	sensores IoT e algoritmos de visão computacional (YOLOv4 e YOLOv5)	sensores IoT de baixa potência, câmeras de infravermelho, sensores de CO2, e um sistema baseado em ROS para coordenação dos UAVs e UGVs.	Não especificada	O YOLOv4 f utilizado no UGV com uma configuração otimizada para dispositivos com CPU, YOLOv5 utilizado no UAV, configurado para detecção em tempo real.	UAVs e UGVs, com comunicação via Wi-Fi e MQTT

Fonte: Desenvolvida pelos autores.
Legenda: YOLOv2 = You Only Look Once version 2; CNN = Convolutional Neural Network; GPU = Graphics Processing Unit; UAV = Unmanned Aerial Vehicle; K-NN = K-Nearest Neighbors; SVM = Support Vector Machine; SWIR1 = Short-Wave Infrared 1; SGD = Stochastic Gradient Descent; WPDSS= Wildfire Prediction and Decision Support System; IoT= Internet of Things; UGVs= Unmanned Ground Vehicles.

Tabela 4 – Resultado das variáveis dependentes

Nr	Autor	Ano	Precisão na Detecção de Incêndios	Tempo de Resposta	Custo-Efetividade
1	Saponara S. et al.	2020	0,9658	1-2 segundos	Solução de baixo custo
2	Xu Y. et al.	2024	F1 score de 27,9%	Não especificado	Não avaliado
3	Govil K. et al.	2020	,67% (validação), 91% (teste), F-1 score de 0,89	Detecta antes de chamadas de emergência	Mais eficaz e menos custoso que métodos tradicionais
4	Shamta I, Demir BE.	2024	96% (YOLOv8), 89% (YOLOv8n)	Não especificado	Uso de UAVs destaca vantagem em termos de custo
5	Kanwal R. et al.	2023	0,9691	Não especificado	Uso de dados abertos e disponíveis globalmente
6	Rad R.	2023	Dice Score de 90,05%, Recall de 89,61%	Não especificado	Importância da transparência no impacto ambiental
7	Mohammed RK.	2022	0,9909	Tempo real	Software gratuito e de código aberto
8	Sathishkumar VE. et al	2023	98,72% (Xception)	Não especificado	Implementação de baixo custo mencionada
9	Wang L. et al	2023	0% (Reduce-VGGNet), 97,35% (CNN otimizado)	Não especificado	Não especificado
10	Young IC. et al.	2023	0,926	Tempo real	Não especificado
11	Davis M, Shekaramiz M.	2023	100% (ResNet-50), 99,221% (Xception)	Não especificado	Não especificado
12	Klubsuwan K, Duangsuwa S.	2023	F1-score: 80,6% (dia, fumaça), 82,5% (dia, ıeimadas), 77,9% (noite, fumaça), 81,9% (noite, queimadas)	Não especificado	Não especificado
13	Wei C. et al	2022	93,50%	Tempo real	Não especificado
14	Oh SH.	2020	99,46% (validação), 98,58% (teste)	Tempo real	Não mencionado
15	Cong PT, Tam NT.	2018	Não especificado	2,6 horas	Detecção precoce pode evitar perdas significativas

16	James GL. et al.	2023	Taxa de erro de 2%	Não especificado	Modelo leve e rápido, adequado para dispositivos móveis
17	Rubab SF. et al.	2024	99,91%	Não especificado	Não especificado
18	Shroff P.	2023	98,6% (hotspots), 98,7% (incêndios)	Não especificado	Drones são mais custo-efetivos
19	Bushnaq OM. et al.	2020	Não especificado	30 minutos	UAV-IoT mais rápido e confiável
20	Ghali R, Akhloufi MA	2022	Não especificado	Não especificado	UAVs de baixo custo
21	Remmelzwaal L.	2023	Não especificado	60 segundos	Redução de custos anuais significativos
22	Pietro B. et al.	2023	Não especificado	Tempo real	Não especificado

Fonte: Desenvolvida pelos autores.
Legenda: YOLOv8n= You Only Look Once version 8 nano; CNN = Convolutional Neural Network; UAV = Unmanned Aerial Vehicle; IoT= Internet of Things.

4. DISCUSSÃO

A revisão da literatura teve como objetivo explorar as diversas abordagens e tecnologias empregadas na detecção e monitoramento de incêndios florestais, com ênfase no tempo de detecção, tempo de resposta, precisão dos sistemas e o impacto desses fatores na eficácia do combate aos incêndios. A análise dos 22 estudos revelou um panorama abrangente das metodologias atuais, incluindo o uso de redes neurais convolucionais (CNNs), dados de satélite, veículos aéreos não tripulados (UAVs) e sistemas de sensoriamento remoto, evidenciando avanços notáveis e desafios persistentes nesse campo de pesquisa.

As redes neurais convolucionais (CNNs) mostraram grande potencial na detecção rápida e precisa de incêndios a partir de dados de vídeo. O estudo de Gagliardi et al.[18] demonstrou que o modelo YOLOv2, implementado em sistemas de monitoramento com câmeras estáticas, alcançou uma precisão de 96,82% e um tempo de detecção de 1 a 2 segundos após o início do incêndio, permitindo alertas quase instantâneos. De forma semelhante, o sistema Fuego, descrito por Govil et al.[7], detectou o incêndio Holy Fire de 2018 com 8 minutos de antecedência em relação à primeira ligação para o 9-1-1, mostrando a eficácia dos modelos CNNs para a detecção precoce de incêndios. No entanto, uma das limitações observadas foi a taxa de falsos negativos, que pode impactar a confiança nas detecções realizadas.

As abordagens baseadas em dados de satélite, como as discutidas por Xu et al.[28], enfrentam desafios em termos de tempo de detecção e precisão. O estudo que utilizou imagens do satélite Sentinel-2 e a arquitetura U-Net obteve um F1-score de 28,1% na detecção de incêndios florestais, indicando limitações na acurácia desses sistemas em comparação com outras metodologias. Por outro lado, abordagens como a de Kanwal et al.[29], que utilizam dados de satélite MODIS combinados com modelos de aprendizado de máquina, como Random Forest, conseguiram uma acurácia de 96,91% na previsão de áreas propensas a incêndios, mostrando que a combinação de técnicas de aprendizado de máquina com dados de satélite pode melhorar a previsão e monitoramento de incêndios.

O uso de UAVs equipados com sensores avançados mostrou-se promissor na detecção de incêndios. Shamta e Demir[30] desenvolveram um sistema de detecção utilizando drones com câmeras e o computador embarcado NVIDIA Jetson Nano, processando as imagens em tempo real com modelos como YOLOv5, YOLOv8, e CNN-RCNN. O modelo YOLOv8 classification obteve a maior acurácia, com 96%. Outro estudo de Duangsuwan e Klubsuwan[31] avaliou a precisão de um sistema de detecção em tempo real utilizando drones, chamado Dr-TOBID, que combina o detector YOLOv5 com um classificador de Memória de Longo e Curto Prazo (LSTM), alcançando F1-Scores de até 82,5% na detecção de fogo durante o dia. No entanto, a

implementação em larga escala ainda enfrenta desafios relacionados a custos e à complexidade operacional.

A taxa de falsos positivos e negativos é um fator crítico para a eficácia dos sistemas de detecção de incêndios. Por exemplo, o modelo Piramidal Espacial - Swin Transformer - UNet. (SP-Swin UNet), proposto por Rad[21], obteve um Dice Score de 90,05% e um Recall de 89,61% na detecção de incêndios florestais, indicando uma baixa taxa de falsos negativos. Esse desempenho é essencial para garantir que os alertas emitidos sejam confiáveis e que poucos incêndios reais deixem de ser detectados.

A revisão também abordou considerações sobre custo-efetividade e escalabilidade dos sistemas de detecção de incêndios. Gagliardi et al.[18] propuseram um sistema de baixo custo utilizando o dispositivo embarcado Jetson Nano e câmeras de vigilância existentes, o que destaca a viabilidade de soluções econômicas. Mohammed[17] também enfatizou a acessibilidade do seu sistema, que pode ser implementado em um dispositivo Raspberry Pi com uma câmera. Esses aspectos são essenciais para a adoção em larga escala de tecnologias de monitoramento de incêndios em regiões com recursos limitados.

A escolha da abordagem mais adequada para a detecção de incêndios florestais depende de uma série de fatores inter-relacionados. Enquanto os sistemas baseados em CNNs e dados de vídeo oferecem alta precisão e tempos de detecção rápidos, as abordagens baseadas em dados de satélite proporcionam uma cobertura ampla, porém com maior latência. O uso de UAVs combina mobilidade e precisão, mas enfrenta desafios de custo e operacionalidade. A integração de múltiplos sensores e fontes de dados surge como uma tendência promissora.

Considerações sobre custo, infraestrutura, condições ambientais e necessidades específicas das regiões afetadas são importantes para orientar a implementação e o desenvolvimento futuro dessas tecnologias. A colaboração interdisciplinar e os investimentos contínuos em pesquisa e desenvolvimento são considerados fundamentais para o aprimoramento das capacidades de detecção e, por conseguinte, para o fortalecimento das estratégias de combate e prevenção de incêndios florestais em escala global, como enfatizam Okoro e Lopez[14].

Apesar da quantidade de estudos encontrados para a presente análise, não foi possível encontrar nenhum estudo que fizesse uma análise simultânea de todas as variáveis dependentes elencadas. Cada estudo focou em aspectos específicos, como precisão, tempo de detecção, tempo de resposta, taxa de falsos positivos e negativos, ou a viabilidade econômica, mas nenhum deles integrou todos esses fatores em uma abordagem única e abrangente. Essa lacuna sugere a necessidade de pesquisas futuras que adotem uma perspectiva mais holística, considerando a interação complexa entre as diferentes variáveis envolvidas na detecção de incêndios florestais. Uma análise integrada poderia fornecer uma visão mais completa e precisa das capacidades e

limitações dos sistemas de detecção, ajudando a desenvolver soluções mais robustas e eficientes que possam ser aplicadas em uma variedade de cenários ambientais e operacionais.

5. CONCLUSÃO

Este trabalho investigou características relevantes à implementação de sistemas de monitoramento controlados por inteligência artificial para a detecção de incêndios florestais. Foram identificadas diversas abordagens e tecnologias consideradas eficazes e que podem contribuir significativamente para aprimorar a capacidade de resposta a incêndios florestais, reduzindo tanto o tempo de detecção e, em consequência, os impactos ambientais e sociais associados.

Os estudos analisados demonstraram que o uso de sistemas baseados em inteligência artificial, como redes neurais convolucionais (CNNs), combinados com dados de sensores remotos e UAVs, pode fornecer uma detecção mais rápida e precisa dos focos de incêndio. Essas tecnologias têm potencial para superar as limitações dos métodos tradicionais, como o monitoramento via satélite, que muitas vezes enfrenta desafios relacionados à precisão e ao tempo de resposta.

Contudo, uma limitação identificada nesta pesquisa foi a falta de integração completa entre variáveis-chave, como precisão, tempo de resposta, viabilidade econômica e taxa de falsos positivos, em um modelo abrangente. Futuras pesquisas devem priorizar essa abordagem holística para garantir a eficácia plena das tecnologias em contextos específicos, como o da Mata Atlântica. A continuidade dos investimentos em pesquisa e desenvolvimento é essencial para que essas tecnologias possam ser plenamente aplicadas, contribuindo para a preservação dos ecossistemas e a segurança das populações.

CONFLITO DE INTERESSES

Os autores declaram não haver conflito de interesses. Todos são militares do Corpo de Bombeiros Militar do Estado do Rio de Janeiro.

REFERÊNCIAS

1. Rodrigues ANC. Considerações sobre prevenção e combate aos incêndios florestais no Estado do Rio de Janeiro. Seropédica: Universidade Federal Rural do Rio de Janeiro, 2008.

2. Câmara Metropolitana do Rio de Janeiro. Plano de Desenvolvimento Urbano Integrado da Região Metropolitana do Rio de Janeiro (PDUI-RMRJ) – Relatório técnico – Produto 2C – Parte 3 – Cenários de expansão urbana [Internet]. 2018 [citado 2024 mar 14]. Disponível em: http://www.rj.gov.br/c/document_library/get_file?uuid=3b534f44-6d02-4c8d-9c6a-8d9f54c0061/

3_Cenarios_Expansao_Urbana_PDS.pdf

3. Price O, Bradstock R. Countervailing effects of urbanization on fuel types and fire likelihood in forested landscapes of south-eastern Australia. Landscape and Urban Planning 2014;130(1):81-88.

4. Corpo de Bombeiros Militar do Estado de Goiás. Manual operacional de prevenção e combate a incêndios florestais. Edição Única. Goiás, 2017.

5. Esteves BB, Aquino Filho GF. SEPIR – Sistema Eletrônico de Prevenção de Incêndios em Rodovias. São Vicente: Faculdade de Tecnologia de São Vicente, 2015.

6. Jones GA, Paragios N, Regazzoni CS. Video-Based Surveillance Systems: Computer Vision and Distributed Processing. 1st ed. Berlin: Springer, 2011.

7. Govil K, Welch ML, Ball JT, Pennypacker CR. Preliminary results from a wildfire detection system using deep learning on remote camera images. Remote Sensing 2020;12(166):1015-1037.

8. Guimarães PP, Souza SM, Fiedler NC, Silva AG. Análise dos impactos ambientais e socioeconômicos causados pelos incêndios florestais no Parque Estadual da Serra de Caldas Novas – Goiás. Academy, Centro Científico Conhecer – Goiânia. 2014;1(1):38-58.

9.Terra Brasilis. Programa Queimadas do INPE [Internet]. [citado 2024 fev 25]. Disponível em: https://terrabrasilis.dpi.inpe.br/queimadas/portal/faq/index.html

10.Universidade de Brasília. Projeto da UnB usa inteligência artificial para identificar incêndios [Internet]. [citado 2024 mar 12]. Disponível em: https://www.unb.br/noticias/unbagencia/publicacoes/entrevistas/25552-projeto-da-unb-usa-inteligencia-artificial-para-identificar-incendios.

11.AlertCalifornia. Technology [Internet]. [citado 2024 fev 21]. Disponível em: https://alertcalifornia.org/technology

12.Sathishkumar VE, et al. Application of artificial intelligence for forest fire detection and prediction in Western US temperate forests. Fire Ecology 2023;19(9).

13.Ghali R, Akhloufi MA. Deep Learning Approaches for Wildland Fires Using Satellite Remote Sensing Data: Detection, Mapping, and Prediction. Fire 2023;6(5):192.

14.Okoro CS, Lopez A, Unuriode OA. A synergistic approach to wildfire prevention and management using AI, ML, and 5G technology in the United States. *Environ Earth Sci*. 2024; 15(7):31-172.

15.Moher D, Liberati A, Tetzlaff J, Altman DG. Preferred reporting items for systematic reviews and meta-analyses: the PRISMA statement. PLoS Med 2009;6(7)

16.Sterne JAC, Savović J, Page MJ, Elbers RG, Blencowe NS, Boutron I, et al. RoB 2: a revised tool for assessing risk of bias in randomized trials. BMJ 2019; 366:14898

17. Mohammed KR. A real-time forest fire and smoke detection system using deep learning. International Journal of Nonlinear Analysis and Applications 2022; 13(1):2053-2063.

18. Gagliardi A , El Hanashi A, Saponara S. Real-time video fire/smoke detection based on CNN in antifire surveillance systems. Journal of Real-Time Image Processing 2020;18(7553):1-12.

19. Davis M, Shekaramiz M. Desert/forest fire detection using machine/deep learning techniques. Fire 2023;6(11):418.

20.Rubab SF, Ghaffar AA, Choi GS. FireDetXplainer: Decoding wildfire detection with transparency and explainable AI insights. IEEE Access 2016;4:1.

21.Rad R. Remote Wildfire Detection using Multispectral Satellite Imagery and Vision Transformers. In: Proceedings of the 15th Asian Conference on Machine Learning (ACML 2023). PMLR. 2024;222:1135-50..

22. Wei C, Xu J, Li Q, Jiang S. An intelligent wildfire detection approach through cameras based on deep learning. Sustainability 2022;14(23):1569.

23.Bushnaq O, Chaaban A, Al-Naffouri TY. The role of UAV-IoT networks in future wildfire detection. IEEE Internet of Things Journal 2021;8(23):16984-16999.

24.Duangsuwan S, Klubsuwan K. Accuracy assessment of drone real-time open burning imagery detection for early wildfire surveillance. Forests 2023;14(1):1852.

25.James GL, Ansaf RB, Al Samahi SS, Parker RD, Cutler JM, Gachette RV, Ansaf BI. An efficient wildfire detection system for AI-embedded applications using satellite imagery. Fire. MDPI 2023;6(4):169.

26. Oh SH, Ghyme SW, Jung SK, Kim GW. Early wildfire detection using convolutional neural network. Frontiers of Computer Vision. Springer 2020;1(1):18-30.

27. Cong PT, Tam NT. Remote sensing meets deep learning: exploiting spatio-temporal-spectral satellite images for early wildfire detection. Preprint. EPFL 2019;9 p

28. Xu Y, Berg A, Haglund L. Sen2Fire: a challenging benchmark dataset for wildfire detection using Sentinel data. In: IGARSS 2024 – 2024 IEEE International Geoscience and Remote Sensing Symposium.

29. Kanwal R, Rafaqat W, Iqbal M, Weiguo S. Data-driven approaches for wildfire mapping and prediction assessment using a convolutional neural network (CNN). Remote Sensing 2023;15(21):5099.

30. Shamta I, Demir BE. Development of a deep learning-based surveillance system for forest fire detection and monitoring using UAV. PLoS ONE 2024;19(3):58.

31. Yang LY, Wang N, Qiao XM. Real-time forest fire detection with wireless sensor networks. International Journal of Distributed Sensor Networks 2005;12(6):760.

32.Shroff P. AI-based wildfire prevention, detection and suppression system. ResearchGate 2023;12:1-15.

33.Battistoni P, Cantone AA, Martino G, Passamano V, Romano M, Sebillo M, Vitiello G. A cyber-physical system for wildfire detection and firefighting. Future Internet. MDPI 2023;15(7):237.